本科毕业论文（设计）

题　　目：基于大模型微调的精神心理对话系统开发

学　　院：自动化与智能学院

专　　业：自动化

学生姓名：陈宇成

学　　号：22221004

指导教师：王焱

北京交通大学

2026 年 5 月

学士论文版权使用授权书

本学士论文作者完全了解北京交通大学有关保留、使用学士论文的规定。特授权北京交通大学可以将学士论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：　　指导教师签名：

签字日期：　　年　　月　　日　　签字日期：　　年　　月　　日

学士论文诚信声明

本人声明所呈交的毕业论文（设计），题目《基于大模型微调的精神心理对话系统开发》是本人在指导教师的指导下，独立进行研究工作所取得的成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：　　日期：

中文摘要

摘要：随着公众心理健康需求不断上升，传统心理咨询在服务成本、可及性、隐私保护和早期筛查方面仍存在明显限制。大语言模型具备自然语言理解、多轮对话和共情表达能力，为低门槛心理支持系统提供了新的技术路径；但通用模型直接用于心理健康场景时，仍可能出现幻觉、状态追踪不足、风险识别不稳和伦理边界模糊等问题。本文以“基于大模型微调的精神心理对话系统开发”为题，结合开题报告、项目中期汇报和实际源码，设计并实现了一套面向心理健康初筛与陪伴支持的端到端原型系统。系统采用评估模型与陪伴模型分阶段协作的双模型架构：评估模型负责建档访谈、周期复评和结构化画像生成，陪伴模型基于最新画像开展持续对话；同时引入本地检索增强生成模块，将 DSM-5-TR 相关知识切分为可追溯片段，在涉及专业内容时为回答提供来源依据。工程实现方面，系统使用原生 JavaScript、HTML 和 Tailwind CSS 完成交互界面、状态机、流式 API 调用、会话存档、画像面板和本地 RAG 检索闭环，并预留模型 ID 配置能力，便于接入 LoRA/SFT 微调后的模型。测试与分析表明，系统能够完成关键词定制、初评建档、JSON 画像生成、持续陪伴、周期复评、知识库命中回显和异常提示等核心流程，具有一定可解释性、可扩展性和工程复现价值。

关键词：大语言模型；心理健康对话系统；LoRA 微调；检索增强生成；结构化评估

ABSTRACT

ABSTRACT: With the growing demand for mental health support, traditional counseling services still face limitations in cost, accessibility, privacy protection, and early screening. Large language models provide a new technical path for low-threshold psychological support because they can understand natural language, sustain multi-turn dialogue, and generate empathetic responses. However, directly applying general-purpose models in mental health scenarios may introduce hallucinations, weak state tracking, unstable risk awareness, and unclear ethical boundaries. This thesis designs and implements an end-to-end prototype system for mental health pre-screening and supportive dialogue based on the proposal, interim presentation, and project source code. The system adopts a staged dual-model architecture: the assessment model handles intake interviews, periodic reassessment, and structured profile generation, while the companion model provides ongoing supportive dialogue based on the latest profile. A local retrieval-augmented generation module is also integrated to split DSM-5-TR knowledge into traceable chunks and provide evidence when professional content is involved. The implementation uses native JavaScript, HTML, and Tailwind CSS to build the user interface, state machine, streaming API calls, conversation archive, assessment dashboard, and local RAG pipeline. Configurable model identifiers are reserved for future LoRA/SFT fine-tuned models. Functional analysis shows that the system supports keyword customization, intake dialogue, JSON-based assessment, continuous companionship, periodic reassessment, knowledge citation display, and error handling, demonstrating interpretability, extensibility, and engineering reproducibility.

KEYWORDS: large language model; mental health dialogue system; LoRA fine-tuning; retrieval-augmented generation; structured assessment

目　　录

1 引言.....8
1.1 研究背景与意义.....8
1.2 国内外研究现状.....9
1.3 研究内容与技术路线.....10
1.4 论文组织结构.....10
2 相关技术基础.....11
2.1 大语言模型与心理健康对话.....11
2.2 LoRA 参数高效微调.....11
2.3 检索增强生成技术.....12
2.4 流式 API 与前端状态机.....12
2.5 安全伦理与应用边界.....12
3 系统需求分析与总体设计.....13
3.1 需求分析.....13
3.2 总体架构设计.....14
3.3 状态机与数据流设计.....14
3.4 系统文件结构.....15
4 关键模块设计与实现.....16
4.1 关键词定制与建档入口.....16
4.2 双模型分阶段调用.....16
4.3 结构化动态评估画像.....17
4.4 本地 RAG 检索与知识回显.....17
4.5 流式 API 与异常处理.....18

4.6 界面与会话管理.....19
5 模型微调与知识库构建方案.....22
5.1 指令数据集构建.....22
5.2 LoRA 训练设计.....22
5.3 知识库构建与质量控制.....23
5.4 评价指标设计.....24
6 系统测试与结果分析.....24
6.1 测试环境.....24
6.2 功能测试.....24
6.3 关键流程分析.....25
6.4 系统优势.....26
6.5 局限性分析.....26
7 结论与展望.....27
7.1 研究结论.....27
7.2 后续展望.....27
参考文献.....28
致　　谢.....28
附　　录.....29
附录 A 项目运行说明.....29

1 引言

1.1 研究背景与意义

精神障碍从个人问题上升为公共健康及社会治理的重大问题已成为共识，《世界精神卫生报告》强调目前全球范围内精神卫生服务存在巨大需求量、覆盖率低以及社会偏见等因素限制了精神卫生服务发展等问题[1]。“健康中国行动(2019—2030年)”中也提出了我国居民心理健康素养提升计划、建立心理危机干预和心理援助服务模式的目标[2]。这意味着，心理健康服务不再是单纯的医疗卫生系统内部专业问题，而是一个教育、社区乃至互联网服务及智能化相关的问题。

人工咨询师一对一的服务具备专业度高、界限感强等特点，但也面临价格昂贵、等待时间长、地区不平衡以及求询者门槛高等客观制约因素。对一些处于问题萌芽阶段、情绪不稳定或暂不具备实地咨询的群体来说，一款价格低廉、可以随时使用、提供初级聆听与预警服务的软件不失为一种现实选择。它可以不代替医生、心理咨询师，但可成为早期筛查、情绪支持和求助引导的入口。

近期大语言模型在语义理解和文本生成、指令跟随、多轮对话等方面得到了长足的发展。相较于早期基于规则或者模板的聊天机器人而言，大模型可以理解用户较为复杂的描述，并能够在开放式的对话环境下产生相对自然的回答。这同样启发了我们对心理对话系统建设的新想法：以用户主诉的症状、情绪强度、睡眠情况、人际关系以及风险线索等逐渐建立档案并随时根据下文进行协助。

然而，心理健康场景是高度敏感的高危场景。通用大模型存在事实幻觉、过度建议、漏掉危机信号、隐私泄露及表达不当等风险。如果模型给出未经验证的诊断或处方可能会对用户产生误导。因此，本课题不求系统替代专业诊疗，只做“心理状态初步筛查和支持式聊天原型”。通过模型分工、结构化评价、本地知识库搜索、风险预警来规避使用风险。

1.2 国内外研究现状

AI 在心理健康领域并不是一蹴而就的。早期 ELIZA 的模式匹配模仿罗杰斯式咨询语言实现了人机对话的情绪陪伴作用，本质上是基于规则的替换，并不具有真正意义上的语义理解 [9] 。之后利用机器学习以及深度学习进行情感分类、抑郁倾向识别及社交媒体的心理状态分析，模型的能力逐渐从浅层特征工程向语义表示学习发展。

随着大语言模型的到来，关注点由单篇文本分类拓展到了开放式的心理健康问答、可解释分析及对话干预上。例如，Mental-LLM 等工作对各类指令微调模型进行了在线文本心理健康预测任务测试，证明大模型在零样本、少样本环境下具有一定的可行性，但同时受制于数据范围、文化和任务定义上的约束[5]。MentaLLaMA 和可解释心理健康分析的相关工作指出心理健康 AI 需要不仅提供标签，还需说明判断的原因以提高可解释性及对决策的价值[6][7]。

在专业性准确性上，检索增强生成(RAG) 被用来解决大模型幻觉的问题，在生成之前检索外部的知识库，并把权威的片段当作 Context 输入给模型，使得答案会受到知识边界的限制[4]。在心理领域里，当涉及诊断标准、症状的解释、鉴别诊断、危机干预的原则等内容时，RAG 是很适用的一种技术手段。但是 RAG 同样存在检索噪声、上下文拼接生硬以及多轮会话中的知识更新不稳定性的问题。

在模型适配上，LoRA 等 PEFT 范式下可以将基座模型的权重冻结住，只对低秩的适配矩阵进行训练便能完成垂直领域的微调，极大节省了垂直领域微调的算力开销[3]。对于高校毕业设计及小批量试验场景而言，LoRA 可提供一种可复用的途径来使用相对较小的标注样本提升模型的风格表达性、指令遵循性及领域任务性能，然后 RAG 补足知识正确性。这样，微调解决 “怎么” 和 “按照怎样的任务格式输出” 的问题，RAG 解决 “根据什么来” 的问题，两者是互补的关系。

现有研究虽然已经覆盖提示工程、RAG、微调和可解释分析等方向，但在面向真实使用流程的系统集成方面仍有不足。多数论文关注单一任务，例如抑郁检测、风险分类或知识问答，较少给出一个完整的“关键词定制、初评建档、动态画像、

长期陪伴、知识库回引、会话存档”的端到端工程原型。本文的切入点正是在系统层面把这些能力组织为可运行的前端应用。

1.3 研究内容与技术路线

围绕精神心理对话系统的工程实现，本文主要完成五项工作：一是建立面向心理健康初筛的需求模型，将系统功能划分为关键词定制、建档访谈、结构化评估、持续陪伴、知识库检索、风险提示和会话管理等模块；二是构建评估模型与陪伴模型分阶段协作机制，将建档任务与陪伴任务解耦；三是实现本地 RAG 检索模块，把 DSM-5-TR 相关资料转换为带页码、哈希和片段编号的知识单元；四是完成浏览器端流式对话界面、画像面板和存档管理；五是结合 LoRA 微调方案讨论后续接入微调模型的可行性。

技术路线可概括为“数据与知识准备、模型分工设计、前端状态机实现、API 流式调用、画像与检索闭环验证”五个环节。首先，根据开题报告对心理健康场景的分析，明确系统定位为辅助性初筛和支持性对话，而非医疗诊断；其次，结合 PPT 中提出的双模型协作思路，将评估模型与陪伴模型绑定到不同阶段；再次，在项目代码中通过配置项、状态变量和统一 API 出口实现模型切换；最后，利用本地知识库与画像面板增强系统回答的可解释性和过程可观察性。

1.4 论文组织结构

本文共分为 7 章。第 1 章阐述了背景、国内外的研究状况、研究的内容及文章安排；第 2 章介绍大语言模型、LoRA 微调、RAG、流式 API 及心理健康安全边界等关键技术；第 3 章进行需求分析及总体架构设计；第 4 章根据项目源码对系统中的几个关键部分做实现描述。在第五章中对数据工程、微调训练以及知识库构建方案进行探讨；在第六章中给出功能测试、结果分析及系统的局限性；最后，在第七章中对本文的工作进行总结，并提出进一步的改进意见。

2 相关技术基础

2.1 大语言模型与心理健康对话

LLM 通常使用 Transformer 在大量的文本上做预训练，并通过指令微调、偏好对齐等方式来增强对用户指令的服从程度，在传统任务型系统的优点基础上增加了可以接收开放域的输入信息、理解上下文及生成自然流畅回答的能力。心理健康对话恰好具有开放性高、歧义性高、情感强度高及上下文相关度高等特点，适合于基于大模型进行交互。

但是心理健康的聊天又不等于闲聊。用户可能描述失眠、持续性的焦虑情绪、自我贬低、创伤事件甚至是自伤的想法。模型不仅要给予语言层面的理解和支持，同时也要注意不过度诊断、不要提供用药指导，在发现危险信号的时候首先引导用户寻求现实世界中可信赖的人以及专业的帮助。所以，系统设计上必须对提示词、状态机、风险提示以及知识来源进行约束。

2.2 LoRA 参数高效微调

全量微调大模型会更新全部参数，训练成本很高并且很容易破坏基座模型的通用能力。LoRA 的主要思想是在不更新原有权重的情况下，对注意力或者前馈网络中的线性层加入低秩矩阵，同时将权重的更新量近似为两个较小矩阵相乘的形式。若原权重矩阵为 W，则微调后得到的新权重可以表示成 W+BA 的形式，其中 A 和 B 是可学习的低秩矩阵。因为可学习参数大大减少，所以 LoRA 适用于资源受限条件下的垂域适配 [3]。

在本课题里，LoRA 微调的目的不是训练一个固定的答案，而是希望模型能学会心理支持对话里的表达风格、结构化信息提取格式和安全拒答策略。即微调的数据应该包括用户的自述、咨询师的回答、评估字段抽取、危机提示以及知识不足时候的保守回答。使用新微调后的模型只需在系统设置中更改模型 ID 即可，在不修改前端框架的情况下就可以实现。

2.3 检索增强生成技术

RAG 使用外部的知识源辅助语言模型进行推理。通常步骤为文档处理、分段、编码或者关键词存储、相似性搜索、片段组合以及答案合成。相对于纯参数化的方法，RAG 可以直接利用可信的信息来源，在一定程度上缓解模型在特定领域的虚假信息问题，并且给出其出处 [4]。

本系统所使用的 RAG 实现为一个较轻量化的浏览器端实现，在知识库中以 document 的 meta data 和 chunks 数组的形式存储了 chunk 中的源信息、页面区间、chunk id、chunk 正文内容的 hash 值以及 chunk 正文等内容；在浏览器端装载好知识库之后，将用户的问题和各个知识库中的知识片断进行 tokenize 后，生成其哈希值，并计算相似性分数，然后再根据综合得分取 TopK 片段注入系统提示词。此方案不需要依赖后端向量数据库，方便做毕业设计展示和静态部署。

2.4 流式 API 与前端状态机

心理对话系统需要较好的实时性，在等待模型完整生成后才显示的话会让用户感觉交互很慢。流式的 API 通常是 Server-Sent Events 或者类似的协议一步步返回增量文本，前端一边接受一边渲染可以模拟出自然的打字效果。项目中 api.js 封装了非流式的 chat 和流式的 streamChat 两种请求，包含超时机制、异常捕获、重试策略。

除通信层外，系统还需要显式状态机来控制对话阶段。本项目将会话划分为 idle、intake 和 therapy 三个状态。idle 表示尚未开始；intake 阶段只调用评估模型；therapy 阶段主要调用陪伴模型，但在达到复评轮次后会插入一次评估模型调用。这样的状态机使系统行为可解释、可测试，也便于在界面上显示当前模型身份。

2.5 安全伦理与应用边界

精神心理领域使用的大语言模型要有边界感。第一是系统输出仅能作为辅助性支持，并不代替精神科诊断、心理治疗或者药物处方。第二是系统应该尽量少地收集身份信息，避免在前端存储较多的身份信息。第三是当用户有自伤、伤人、极端

绝望或者现实无法控制的信号时，对系统来说，应当先确认安全，再提示线下帮忙，而不是继续进行日常对话。

因此，本系统在定位上采用“初筛与陪伴支持”而非“自动诊疗”。其价值主要在于降低早期求助门槛、帮助用户梳理问题、在必要时引导专业求助，并为后续人工服务提供结构化摘要。

3 系统需求分析与总体设计

3.1 需求分析

结合开题报告及项目 PPT 可知，设计目标是将一款普通的聊天软件升级成具有要素化的采集、检索增益的心理对话原型，主要服务对象是在生活中遇到情绪困扰、学业压力、恋爱困惑、工作焦虑以及失眠的人群。需要提供一种温和、低门槛的入口，并能谨慎地进行专业的知识表达，在危险信号上保持敏感度。

需求类别	具体要求	实现方式
交互需求	支持关键词定制、多轮对话、流式回复	index.html 与 ui.js 构建聊天界面和关键词面板
评估需求	在初评阶段采集主诉、情绪、睡眠、功能受损和支持系统	config.js 提示词与 main.js 状态机控制评估模型
画像需求	生成压力、内耗、风险、恢复弹性等结构化指标	generateAssessment 解析 JSON 并写入报告面板
知识需求	涉及专业知识时尽量基于可追溯资料回答	rag.js 检索 DSM-5-TR 知识片段并注入提示词
安全需求	识别高风险等级并提示现实支持资源	warningLevel 与 crisisSignals 驱动界面提示
管理需求	允许保存、恢复和删除历史会话	localStorage 保存 archives 快照

表 3-1 系统核心需求与实现方式

3.2 总体架构设计

系统整体架构为一个运行在浏览器上的单页应用，前端完成页面渲染、用户输入收集、当前状态维护、内部知识库搜索以及对应 API 调用等功能；外部大模型服务提供 chat completions 接口，同时支持 OpenAI 的格式；本地知识库为 JSON/JS 文件，被加载到项目当中。架构的核心并不是单纯地将两个模型放到界面上进行配置的问题，而是在不同的阶段由两个模型来执行不同的工作。

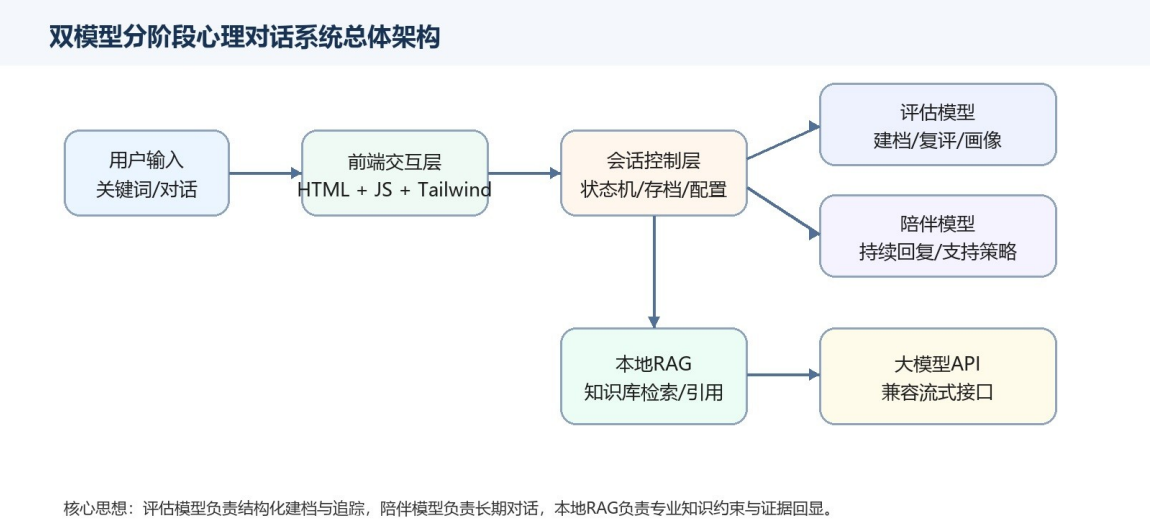

图 3-1 双模型分阶段心理对话系统总体架构

评估模型主要是事实采样与结构化输出，所以 temperature 值较低，并在 prompt 中着重于客观、简洁以及 JSON 格式约束；陪伴模型主要是情绪支持与持续对话，因此 temperature 较高，prompt 更多是共情、承接与安全边界；而 RAG 模块并不直接给出答案，在检索命中后将额外的 system prompt 插入 model message 中，限制模型的回答被知识片段所控制。

3.3 状态机与数据流设计

系统显式状态机由 idle、intake 和 therapy 三个阶段构成。用户选择 1 到 5 个心理关键词后进入 intake 阶段，系统调用评估模型发起建档访谈。达到设定轮次后，评估模型生成结构化画像，系统切换到 therapy 阶段。此后用户每输入若干轮，系统自动触发复评，更新画像并重建陪伴模型的系统提示词。

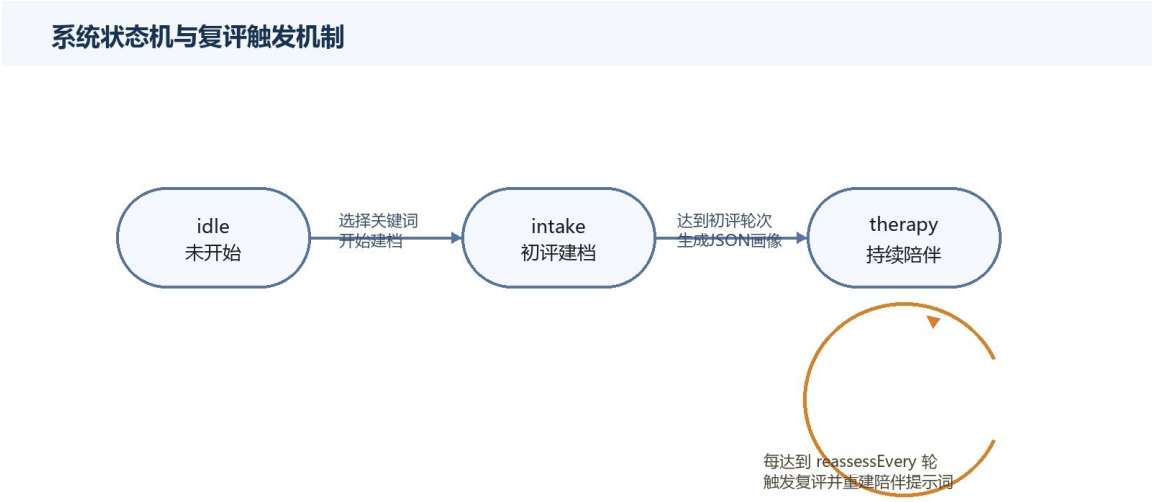

图 3-2 系统状态机与周期复评机制

数据流方面，用户消息首先写入 State.history 与 displayMessages；若启用 RAG，系统会根据当前 userQuery 检索知识库并生成 sources；随后通过 streamAssistantReply 调用指定模型。模型返回文本后，UI 实时渲染，并将 assistant 消息回写至会话历史。评估报告则单独保存到 reports 与 latestReport 中，供画像面板展示和后续提示词重建使用。

3.4 系统文件结构

文件	行数	主要职责
index.html	382	页面结构、样式和主要交互区域
config.js	147	模型默认配置、关键词列表、系统提示词模板
main.js	653	会话状态机、双模型调用、画像生成、存档管理
api.js	212	兼容接口请求、流式响应解析、重试与错误处理
rag.js	204	本地知识库加载、分词、向量化、TopK 检索
ui.js	652	界面渲染、报告面板、消息气泡、设置弹窗
tools/pdf_to_rag_json.py	491	PDF 解析、OCR、切块与 JSON/JSONL/JS 输出

表 3-2 项目主要源码文件与职责

4 关键模块设计与实现

4.1 关键词定制与建档入口

系统预置 20 个常见心理议题关键词，包括原生家庭、亲密关系、职场内耗、存在焦虑、自我价值、讨好模式、完美主义、拖延自责、焦虑失控、低落麻木、睡眠紊乱、社交耗竭、依恋创伤、创伤记忆、边界感、容貌身材、信息过载、学业压力、经济压力和失恋恢复。用户从中选择 1 至 5 项后，系统会把这些议题写入评估模型提示词，从而形成更贴近个体处境的建档语境。

关键词并不是为用户提供标签，而是一个温柔的方向指引。比如当用户选择了“职场内耗”，就会更加聚焦于工作压力、职业倦怠、边界问题等内容；如果用户选了“原生家庭”，则会更加聚焦在长期的关系模式以及安全感的来源等问题上。这样做的好处在于不会剥夺用户的主动权，在开始阶段也不会让用户有面对量表式的压迫感。

4.2 双模型分阶段调用

项目的核心实现位于 main.js。loadSettings 函数读取 API Base、API Key、评估模型、陪伴模型、建档轮次、复评间隔和 RAG 参数。startIntakeFlow 函数将系统切换到 intake 阶段，并通过 Config.prompts.buildAssessSystem 生成评估系统提示词；随后调用 streamAssistantReply，并把 assessModel 作为 model 参数传入，同时记录 assessment 角色和“建档开场提问”或“建档追问”的阶段标签。

当 intakeTurnsCompleted 达到设定阈值后，finishInitialAssessment 函数调用 generateAssessment('initial')生成初始画像。画像生成完成后，系统进入 therapy 阶段，通过 rebuildTherapyContext 把最新评估报告写入陪伴模型提示词，并调用 therapyModel 生成第一条陪伴回复。之后在 stage=therapy 阶段，每当 therapyTurnsSinceReview 达到 reassessEvery 设定值，maybeReassessBeforeTherapyReply 会先触发评估模型复评，再进入陪伴模型回复。

这种架构的优点是职责清晰：评估模型更像“结构化记录员”，陪伴模型更像“支持性对话者”。两者共享会话历史，保证上下文连续；同时通过阶段标签、模型 ID 和报告元数据让模型切换在界面上可观察。

4.3 结构化动态评估画像

评估画像是系统区别于普通聊天机器人的关键能力。评估模型不只输出自然语言总结，而是被要求严格返回 JSON 字符串。字段包括 stage、stress、friction、risk、resilience、warningLevel、coreIssue、cognitivePattern、supportFocus、recommendedStyle、summary、nextSteps、crisisSignals、trend 和 followUp。其中 parseReport 函数负责对模型返回中的 JSON 对象进行解析，normalizeReport 负责数值范围约束、默认值补齐和风险等级归一化处理。

界面将压力负荷、内耗拉扯、风险程度和恢复弹性以进度条方式呈现，并展示关键痛点、认知图式、陪伴关注点、建议方式和下一步动作。该可视化结果不用于疾病诊断，而是帮助用户与系统共同把握当前对话阶段；对后续陪伴模型而言，画像也会作为动态提示词的一部分，使回答更贴近用户当下状态。

画像字段	含义	用途
stress	压力负荷，0 到 100	衡量当前压力强度
friction	情绪和认知内耗程度	判断是否需要先做情绪稳定
risk	风险水平	驱动高风险提示与安全优先策略
resilience	恢复弹性	辅助判断用户可执行行动强度
warningLevel	low/medium/high/critical	用于界面风险徽标与危机提醒
nextSteps	下一步支持建议	提供可执行的小行动

表 4-1 结构化评估画像核心字段

4.4 本地 RAG 检索与知识回显

项目包含一份 DSM-5-TR 相关本地知识库，document 元数据记录显示该知识库共 38 页、61 个 chunk，解析方式为 PyMuPDF + RapidOCR，chunk_size 为 900，

chunk_overlap 为 120。每个 chunk 保留 source_path、source_sha256、page_start、page_end、chunk_id、text_sha256 和 citations 等字段，从而支持来源追踪。

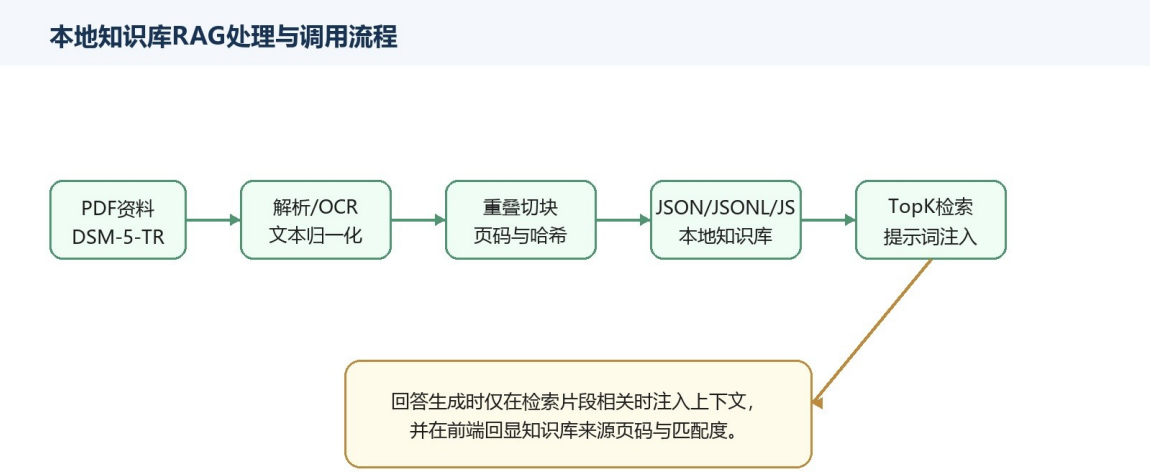

图 4-1 本地知识库 RAG 处理与调用流程

rag.js 的 tokenize 函数分别对英文术语及中文连贯文本进行切片：前者抽取含有英文字母、数字以及常用标点的词语，后者则切割成长度为 2 和 3 的字符序列，这是因为中文没有单词间隔；vectorize 将 token 按照 FNV 类似哈希算法转换为维度为 512 的 Float32Array 向量表示，并按长度加权后归一化。search 函数对查询向量和 chunk 向量进行余弦相似度打分，并结合词项重合得分数值，最终以 0.84 的向量得分及 0.16 的词项重合得分进行加权排序。

当检索结果的 score 达到 minScore 阈值时，buildRagAugmentedMessages 会调用 Config.prompts.buildRagContextPrompt 构造额外系统提示词，将知识片段内容、页码和知识库标题注入模型上下文。回答完成后，UI 会展示知识来源卡片，包括页码、匹配度和文本预览，使用户能够看到回答依据，而不是只能依赖模型自身表述。

4.5 流式 API 与异常处理

api.js 对模型调用进行统一封装。其中 nonStreamRequest 用于普通 JSON 评估等需要完整响应的场景；streamRequest 用于聊天回复，通过 ReadableStream 逐行解析

data 字段，从 choices 中提取 delta.content 并追加到 fullText。若流式返回为空，streamChat 会回退到普通 chat 调用，以提高异常情况下的稳定性。

重试相关 makeError 函数会从返回 JSON 或文本中获取错误信息，shouldRetry 函数判断 429、5xx、AbortError 和网络 TypeError 是否可以重试，默认 chat 最多重试 2 次，streamChat 默认重试 1 次。这种设计可降低临时性网络抖动影响对话过程，并在 API Key 失败、模型未返回以及知识库读取失败等情况提供可视反馈信息。

4.6 界面与会话管理

ui.js 实现界面逻辑：关键词按钮、聊天气泡、模型阶段标签、报告面板、风险徽标、知识库引用卡、设置弹窗及会话存档列表；助手每条消息上方显示模型角色、阶段标签及模型 ID，“评估模型·建档追问·qwen-turbo-latest”、“陪伴模型·陪伴回复·qwen3-max-preview”。这样就可以让用户直观地看到两个模型之间的切换了。

会话存档模块使用 localStorage 保存快照，内容包括 phase、selectedTagIds、history、displayMessages、reports 和 latestReport 等数据。用户可以暂停当前对话，并保存、恢复或删除历史记录。对于心理支持场景而言，存档有助于保持陪伴连续性，但也带来隐私风险，因此真实部署时应增加加密、归档、权限控制和用户授权等机制。

为了说明系统页面和交互流程，本文选用模拟对话生成的运行截图，不包含真实用户隐私信息。截图依次展示关键词入口、建档访谈、知识库引用、动态画像、陪伴回复和配置中心等界面，可与本章前述模块设计相互印证。

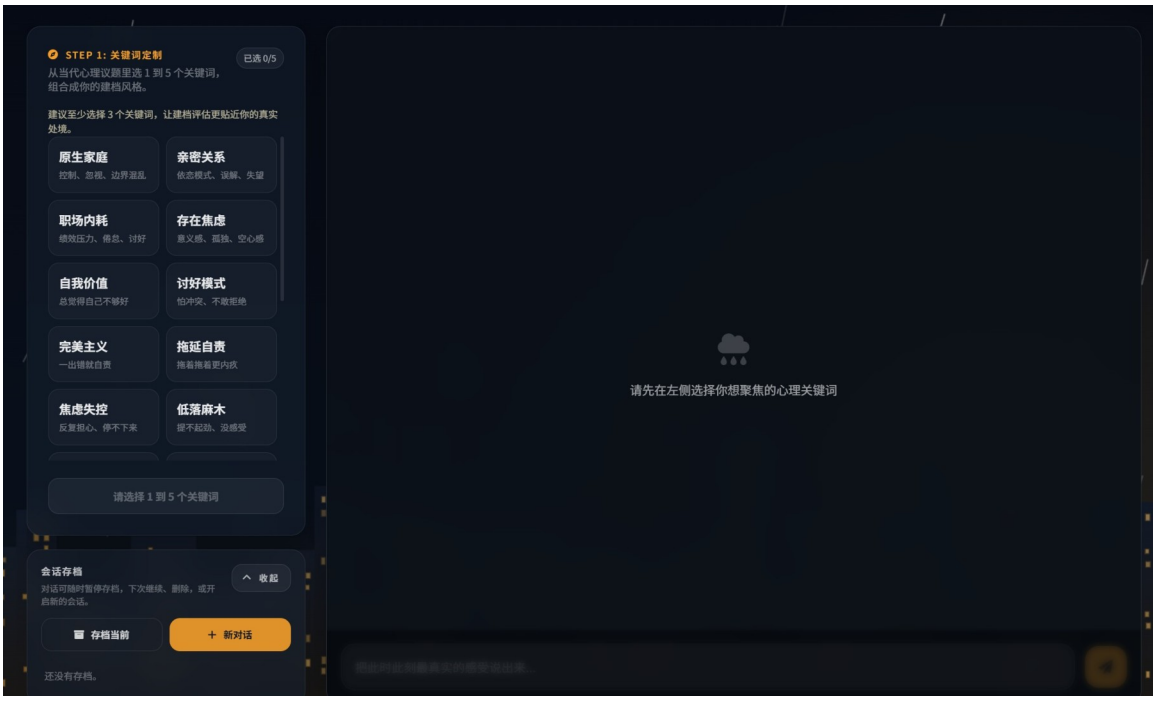

图 4-2 系统首页与关键词定制界面

图 4-3 初评建档阶段与知识库引用回显

图 4-4 动态心理状态画像与持续陪伴界面

图 4-5 双模型与本地 RAG 配置中心

5 模型微调与知识库构建方案

5.1 指令数据集构建

课题申报书及汇报 PPT 中将数据工程作为重要工作方向之一，并在心理对话数据集分类中包含一般性困惑、表述形式、咨询回复、结构化测评、危机干预等类别，并指出由于涉及个人隐私信息，因此收集的实际数据无法直接用于训练集，可采用开放信息采集+人工去敏感重述+领域知识抽取+大模型补全的方式获取训练数据。并进行人工抽检。

训练样本可组织为三类。第一类是建档访谈样本，要求模型每轮只问一个自然问题，并逐步采集情绪强度、诱发事件、持续时间、睡眠和功能受损情况。第二类是陪伴回应样本，要求模型先承接情绪，再进行轻量澄清或具体行动建议。第三类是结构化抽取样本，要求模型根据对话历史输出固定 JSON 格式画像。

样本类型	输入	输出	训练目标
建档访谈	关键词与用户初始描述	一个温和追问	学习低压、单问题推进方式
陪伴对话	历史画像与用户新输入	情绪承接和小步建议	学习共情表达与连续支持
结构化评估	多轮对话历史	合法 JSON 画像	学习字段抽取和格式遵循
安全拒答	诊断、药物、自伤等高风险输入	边界说明与求助引导	学习安全策略和保守输出

表 5-1 指令微调数据类型设计

5.2 LoRA 训练设计

LoRA 训练可以选择 Qwen 或者 Llama 系列中文能力强的基座模型。在训练的过程中冻结基座模型，并在线性层(或者注意力投影) 中加入 LoRA 来训练。重要的超参是 r，alpha，dropout，learning rate，batchsize，epoch 和 maxlen。在毕业设计规模的数据上，训练轮数不宜过多，防止模型对少量模板句式进行过拟合。

本文系统实现层面已经把模型 ID、API Base、enable_thinking 和温度参数做成可配置项，因此微调后的模型只要兼容 chat completions 接口，就可以替换默认评估模型或陪伴模型。工程上不需要改变会话状态机和 UI，只需在设置面板填写微调模型 ID。这样的解耦方式降低了模型实验与前端开发之间的耦合度。

参数	建议范围	说明
r	8/16/32	低秩矩阵秩，越大可训练容量越强
alpha	16/32/64	控制 LoRA 更新缩放
dropout	0.05-0.1	降低小数据过拟合
learning rate	1e-5 到 2e-4	视基座模型和数据规模调整
epochs	3-5	PPT 中期方案采用 3 到 5 轮
max length	2048-4096	覆盖多轮对话和画像输出

表 5-2 LoRA 训练超参数建议

5.3 知识库构建与质量控制

工具代码 tools/pdf_to_rag_json.py：负责 PDF 到 RAG 数据格式的转换过程。在该模块中首先依次尝试 pypdf、PyPDF2、PyMuPDF 和 pdfplumber 抽取文本，在纯文本抽取失败后可以利用 PyMuPDF 渲染出图片然后借助 RapidOCR 进行识别。文本归一化过程包括中文断行合并、空白及页内段落处理，并根据 chunk_size 和 chunk_overlap 产生重叠切块。

为了保证可追溯性，脚本为每个知识块写入 source_sha256、text_sha256、page_start、page_end 和 citations。这样即便知识库被复制到前端静态目录，系统仍能追踪每条回答依据来自哪一页资料。质量控制方面，抽查前 10 个 chunk 和跨页 chunk 及诊断标准页，查看是否有页眉页脚混入、分栏顺序错误、OCR 错字和表格丢失等情况。

5.4 评价指标设计

模型和系统评价不能只看回复是否流畅。结合心理健康场景，本文设计了四类评价指标：任务完成度、表达质量、安全合规和知识可追溯性。

评价维度	指标示例	判断方法
任务完成度	是否完成建档、画像、复评和陪伴	功能测试与流程走查
表达质量	共情性、简洁性、是否一次只推进一个问题	人工评分或 LLM-as-a-Judge
安全合规	是否避免诊断和药物建议，是否识别危机信号	安全用例测试
知识可追溯	专业陈述是否附带知识库页码	RAG 命中与引用回显检查
结构化能力	JSON 是否合法，字段是否完整	自动解析成功率统计

表 5-3 系统与模型评价指标

6 系统测试与结果分析

6.1 测试环境

本系统为浏览器端静态项目，主要运行环境为现代桌面浏览器。项目默认 API Base 为阿里云 DashScope 兼容接口，默认评估模型为 qwen-turbo-latest，默认陪伴模型为 qwen3-max-preview。知识库路径为./data/kb/dsm5_psychosis_zh.json，同时提供 JS 版本知识库以供直接挂载至 window.AppKnowledgeBases。

测试以功能流程和代码走查为主，重点验证状态机是否按预期切换、RAG 是否能加载知识库、JSON 画像是否能够被解析、UI 是否能够展示模型阶段与知识来源。由于心理健康对话涉及真实用户安全，本课题未将系统用于真实诊疗场景，测试样例均为模拟输入。

6.2 功能测试

测试项	输入或操作	预期结果	结果

关键词选择	选择“学业压力”“焦虑失控”	开始按钮可用，预览显示所选方向	通过
初评建档	点击开始初评	进入 intake 阶段并调用评估模型	通过
结构化画像	达到建档轮次	评估模型输出 JSON 并渲染报告面板	通过
持续陪伴	在 therapy 阶段发送新消息	调用陪伴模型流式回复	通过
周期复评	therapy 轮次达到阈值	先复评再继续陪伴回复	通过
RAG 检索	输入与精神病性症状相关问题	命中本地知识片段并显示页码	通过
会话存档	保存并重新加载会话	恢复消息、阶段、画像和关键词	通过
异常提示	未配置 API Key 时开始	弹出设置提示并阻止请求	通过

表 6-1 系统功能测试结果

6.3 关键流程分析

从测试结果看，系统的核心流程能够闭环运行。初评阶段的关键是 intakeTurns 计数与评估模型调用保持一致；陪伴阶段的关键是 therapyTurnsSinceReview 触发复评后必须重建系统提示词，否则陪伴模型无法感知最新画像。项目代码在 generateAssessment 完成后重置 therapyTurnsSinceReview，并在 rebuildTherapyContext 中写入 latestReport，保证状态更新能够影响后续回复。

RAG 流程的优势在于轻量、可离线加载和可解释。当前实现不依赖 FAISS 等后端向量库，而是在浏览器端用哈希向量和词项重叠计算相关度。这种方式便于演示和部署，但语义表达能力弱于真正的嵌入模型。对于毕业设计原型而言，它已经能够展示知识库切块、检索、提示注入和引用回显的完整链路；如果用于实际生产，则应该用 bge-m3 这类嵌入模型加上重排序器替代。

双模型架构的运行过程也具有较强可观察性。每条助手消息和每份评估报告都记录 model、role、stage 和 stageLabel，前端能够直接显示当前由哪个模型承担回

复。相比只在设置面板保留两个模型输入框，这类元数据记录更能说明模型在运行时确实发生了阶段切换。

6.4 系统优势

- 流程闭环较完整：关键词选择、建档访谈、画像生成、陪伴回复和复评更新由同一状态机串联，演示路径连续。
- 模型分工较明确：评估模型负责信息采样与结构化输出，陪伴模型负责支持性回应，减少单一提示词同时承担多种角色造成的混乱。
- 知识来源可以回看：本地 RAG 保留页码、片段编号和匹配分数，涉及知识库内容的回答能够显示引用依据。
- 运行部署较轻量：前端基于原生 JavaScript 和静态文件实现，不依赖复杂后端，便于毕业设计展示、调试和迁移。
- 扩展接口较充足：API Base、模型 ID、建档轮次、复评间隔和 RAG 阈值均可配置，后续接入微调模型或后端服务成本较低。

6.5 局限性分析

一是当前项目仓库主要体现前端原型和本地 RAG 链路，微调训练过程与 LoRA 权重尚未直接封装在仓库中。因此，本文将微调部分作为系统方法与接入方案进行说明，而不声称前端仓库已包含完整训练流水线。后续应补充训练脚本、数据版本、loss 曲线、评测日志和模型权重管理说明。

二是本地 RAG 基于哈希向量和词项重叠，可以满足轻量演示，但对同义表达和复杂语义关系的召回能力有限。心理健康用户常使用模糊表达，如“心里堵”“脑子里不停转圈”“什么都不想动”，简单词项检索未必能稳定命中专业知识片段。

第三，系统当前使用 localStorage 保存会话，对隐私保护不够充分。真实部署需要引入加密存储、用户授权、自动过期、脱敏导出和数据删除机制。最后，系统的安全策略仍主要依赖提示词和风险字段，面对复杂危机个案时仍可能不足，必须强调人工专业支持和线下求助。

7 结论与展望

7.1 研究结论

本文围绕“基于大模型微调的精神心理对话系统开发”完成了需求分析、总体设计、主要模块实现描述、微调与知识库设计方案和功能测试分析。系统将大语言模型应用到心理健康初筛和支持性对话场景中，并通过评估模型与陪伴模型分阶段协作，缓解传统聊天系统缺乏结构化跟踪和模型角色混淆的问题。

项目源码表明，系统已实现关键词定制、建档访谈、评估画像、持续陪伴、周期复评、本地知识库检索、流式 API、会话存档和模型阶段可视化等核心功能。RAG 模块将 DSM-5-TR 相关资料转换为带页码和哈希的知识片段，并在检索命中后注入提示词，让专业性的答案也具有一定的溯源依据。同时，系统也预留了模型设置的能力，这将为后续 LoRA 或者 SFT 的微调提供工程上的可能。

在毕业设计的角度下，本文的价值主要体现在将开题报告中提出的技术路线“微调 + RAG + 要素化采集”落地为一个可以运行、解释、扩展的端到端的原型中，在仍然无法代替专业心理咨询以及医学诊断的前提下，作为早期的情绪支持、问题梳理和风险提示工具有一定的探索意义。

7.2 后续展望

后续工作可从四个方面展开：一是补全完整微调实验，形成数据清洗、LoRA 训练、自动评测、人工抽检和消融实验闭环，并接入现有双模型架构；二是升级 RAG 检索能力，引入语义嵌入模型、向量数据库和重排序器，提高对中文口语化表达的召回能力；三是强化安全机制，在输入端、生成端和输出端分别加入风险识别、危机模板、人工转介和输出审核；四是完善隐私与部署方案，加入本地加密、数据脱敏、权限管理和用户知情同意机制。

此外，系统还可以扩展移动端适配、长期记忆摘要、用户主动删除记录、心理量表辅助填写和咨询师后台查看等功能。但无论技术如何发展，心理健康 AI 都应坚

持辅助定位：帮助用户更早识别问题、更容易表达困扰、更顺畅地连接现实支持，而不是取代专业人员的判断。

参考文献

[1] World Health Organization. World mental health report: transforming mental health for all[R]. Geneva: World Health Organization, 2022.

[2] 健康中国行动推进委员会. 健康中国行动（2019-2030 年）[R]. 北京, 2019.

[3] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]//International Conference on Learning Representations. 2022.

[4] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems. 2020.

[5] Xu X, Yao B, Dong Y, et al. Mental-LLM: Leveraging Large Language Models for Mental Health Prediction via Online Text Data[J]. arXiv preprint arXiv:2307.14385, 2023.

[6] Yang K, Ji S, Zhang T, et al. Towards Interpretable Mental Health Analysis with Large Language Models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 6056-6077.

[7] Yang K, et al. MentaLLaMA: Interpretable Mental Health Analysis on Social Media with Large Language Models[J]. arXiv preprint arXiv:2309.13567, 2023.

[8] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems. 2017.

[9] Weizenbaum J. ELIZA: A Computer Program for the Study of Natural Language Communication Between Man and Machine[J]. Communications of the ACM, 1966, 9(1): 36-45.

[10] Stade E C, Stirman S W, Ungar L H, et al. The opportunities and risks of large language models in mental health[J]. JMIR Mental Health, 2024.

[11] American Psychiatric Association. Diagnostic and Statistical Manual of Mental Disorders, Fifth Edition, Text Revision[M]. Washington, DC: American Psychiatric Association Publishing, 2022.

[12] 国家卫生健康委等. 关于印发健康中国行动（2019-2030 年）的通知[R]. 2019.

致　　谢

本论文以及毕业设计项目得以完成，在此感谢导师王焱老师给予的帮助与指导，从题目方向到系统设计，再到论文框架及工程思路都得到了老师的耐心指导，让我得以将大语言模型、心理健康应用及前端工程有了一个比较明确的方向进行融合。

感谢自动化与智能学院给予的学习平台及课程训练，让我具备了完成本课题所需要的程序设计、智能系统和工程实践基础；感谢同学和朋友们在项目演示、界面体验以及论文修改过程中提出的意见；感谢家人在我毕业设计期间的理解和支持。

附　　录

附录 A 项目运行说明

由于本项目是静态前端应用，因此可以直接用浏览器打开 index.html 进行界面预览。如果浏览器不允许读取本地 JSON 文件，则可以在项目根目录运行一个任意静态文件服务器之后再访问页面即可。使用之前需要在设置面板里填上 OpenAI 兼容格式的 API Base、API Key、评估模型 ID 和陪伴模型 ID。

默认的知识库文件为 data/kb/dsm5_psychosis_zh.json，如果采用 JS 版本的知识库则需在 HTML 中加载 data/kb/dsm5_psychosis_zh.js，并将其挂载至 window.AppKnowledgeBases。典型参数设置举例：assessModel=qwen-turbo-latest，therapyModel=qwen3-max-preview，intakeTurns=4，reassessEvery=6，ragTopK=3，ragMinScore=0.12。